

Лабораторна робота №7

Тема: Поглиблене вивчення MongoDB: оптимізація продуктивності, використання шардінгу та реплікації, інтеграція з Pandas та Machine Learning

З дисципліни: Базы даних та інформаційні системи

Студента групи МІТ-31: Дашковського М. О.

Хід роботи

Частина 1: Оптимізація продуктивності запитів

Для початку роботи було встановлено розширення MongoDB for VS Code.




Рисунок 7.1 – Встановлення розширення

Далі було встановлено підключення до сервера MongoDB.




Рисунок 7.2 – Підключення встановлено

Наступним кроком було створення колекції sales у бд performance test.




Рисунок 7.3 – Створення нової колекції

Далі було створено та запущено скрипт на Python для генерації та вставки 100000 документів до колекції sales.

```
from pymongo import MongoClient
import random
import datetime

client = MongoClient("mongodb://localhost:27017/")
db = client["performance_test"]
collection = db["sales"]

categories = ["Electronics", "Clothing", "Books", "Home", "Sports"]

documents = [
    {
        "customer_id": random.randint(1, 1000), # Випадковий ідентифікатор покупця (1-1000)
        "category": random.choice(categories), # Випадкова категорія з `categories`
        "amount": random.uniform(5, 500), # Випадкова сума покупки (від $5 до $500)
        "timestamp": datetime.datetime(2024, random.randint(1, 12), random.randint(1, 28))
        # Випадкова дата у 2024 році (будь-який місяць і день до 28)
    }
    for _ in range(100000) # Генерація 100 000 документів
]

collection.insert_many(documents) # Вставка документів у колекцію
```

Рисунок 7.4 – Скрипт для генерації документів




Рисунок 7.5 – У колекції sales 100000 документів

Далі було створено скрипт query_no_index.py що вимірює час запиту для отримання всіх документів sales, де значення поля Category – Electronics.

```
from pymongo import MongoClient
import time

client = MongoClient("mongodb://localhost:27017/")
db = client["performance_test"]
collection = db["sales"]

time_start = time.time()

electronics_sales = collection.find({"category": "Electronics"}).to_list()

time_end = time.time()
time_diff = time_end - time_start
print(f"Time taken to query sales in Electronics category: {time_diff:.2f} seconds")
```

Рисунок 7.6 – Код скрипту

Time taken to query sales in Electronics category: 0.22 seconds

Рисунок 7.7 – Результат виконання

Після цього було створено та запущено скрипт create_index.py для створення індекси для категорій та знову запущено query_no_index.py для порівняння швидкості.

```
from pymongo import MongoClient

client = MongoClient("mongodb://localhost:27017/")
db = client["performance_test"]
collection = db["sales"]

collection.create_index([("category", 1)]) # Створення індексу на поле category
print("Index on 'category' field created successfully.")
```

Рисунок 7.8 – Код create_index.py

Time taken to query sales in Electronics category: 0.16 seconds

Рисунок 7.9 – Швидкість виконання запиту після додавання індексу

Індексація прискорила роботу запиту приблизно на 27%.

Далі було створено складений індекс (category, timestamp) з використанням MongoDB Compass. Після цього було виконано запит {"category": "Electronics"} та переглянуто вкладку Explain.




Рисунок 7.10 - Створення складеного індексу у MongoDB Compass

Explain Plan

Explain provides key execution metrics that help diagnose slow queries and optimize index usage. [Learn more](#)




Рисунок 7.11 – Вкладка Explain. Використовується попередньо створений індекс `category_1`

Як бачимо, новий, складений індекс не було застосовано. Щоб використовувався саме він можна видалити попередній.

Explain Plan

Explain provides key execution metrics that help diagnose slow queries and optimize index usage. [Learn more](#)




Рисунок 7.12 – Після видалення старого індекса застосовується складений

Частина 2: Налаштування реплікації

Для початку роботи було запущено три екземпляри MongoDB в різних терміналах з параметром `--replSet`. Далі було виконано підключення до 1шого з них за допомогою MongoDB Compass, після чого виконано команди ініціалізації реплікації та додавання інших екземплярів.

```
rs.initiate()
{
  info2: 'no configuration specified. Using a default configuration for the set',
  me: 'localhost:27017',
  ok: 1,
  '$clusterTime': {
    clusterTime: Timestamp({ t: 1745607620, i: 1 }),
    signature: {
      hash: Binary.createFromBase64('AAAAAAAAAAAAAAAAAAAAAAAAAA=', 0),
      keyId: Long('0')
    }
  },
  operationTime: Timestamp({ t: 1745607620, i: 1 })
}
rs.add("localhost:27018")
{
  ok: 1,
  '$clusterTime': {
    clusterTime: Timestamp({ t: 1745607638, i: 1 }),
    signature: {
      hash: Binary.createFromBase64('AAAAAAAAAAAAAAAAAAAAAAAAAA=', 0),
      keyId: Long('0')
    }
  },
  operationTime: Timestamp({ t: 1745607638, i: 1 })
}
rs.add("localhost:27019")
{
  ok: 1,
  '$clusterTime': {
    clusterTime: Timestamp({ t: 1745607714, i: 1 }),
```

Рисунок 7.13 – Команди налаштування реплікації

```
> rs.status().members.map(m => ({ name: m.name, state: m.stateStr}))
< [
  { name: 'localhost:27017', state: 'PRIMARY' },
  { name: 'localhost:27018', state: 'SECONDARY' },
  { name: 'localhost:27019', state: 'SECONDARY' }
]
```

Рисунок 7.14 – Перевірка роботи кластеру реплікації

Після відключення екземпляра зі статусом “PRIMARY”, цей статус переходить до іншого.

```
rs.status().members.map(m => ({ name: m.name, state: m.stateStr}))
[
  { name: 'localhost:27017', state: '(not reachable/healthy)' },
  { name: 'localhost:27018', state: 'PRIMARY' },
  { name: 'localhost:27019', state: 'SECONDARY' }
]
```


Рисунок 7.15 – Оновлений статус

Частина 3: Реалізація шардінгу

Для початку роботи було запущено ще 2 екземпляри MongoDB:

```
mongod --shardsvr --port 27021 --dbpath D:/data/shard1 --bind_ip localhost --replSet shardSet1
mongod --shardsvr --port 27022 --dbpath D:/data/shard2 --bind_ip localhost --replSet shardSet2
```

Після цього до кожного з них було підключено mongosh та виконано rs.initiate()



```
> rs.initiate()
< {
  info2: 'no configuration specified. Using a default configuration for the set',
  me: 'localhost:27021',
  ok: 1,
  '$clusterTime': {
    clusterTime: Timestamp({ t: 1745610365, i: 1 }),
    signature: {
      hash: Binary.createFromBase64('AAAAAAAAAAAAAAAAAAAAAAAAAAAA=', 0),
      keyId: Long('0')
    }
  },
  operationTime: Timestamp({ t: 1745610365, i: 1 })
}
```

Рисунок 7.16 – Команда rs.initiate()

Наступний крок – ініціалізація сервера конфігурації mongos. Для цього завдання було запущено ще один екземпляр mongod, ініціалізовано його та запущено mongos:

```
mongod --configsvr --replSet configReplSet --port 27019 --dbpath D:\data\config1 --bind_ip localhost
```

```
mongos --configdb replSet/localhost:27017,localhost:27018,localhost:27019 --bind_ip localhost --port 27016
```

Після цього було виконано підключення mongosh до серверу mongos та додано «шарди».

```

sh.addShard("shardSet1/localhost:27021")
{
  shardAdded: 'shardSet1',
  ok: 1,
  '$clusterTime': {
    clusterTime: Timestamp({ t: 1745611315, i: 14 }),
    signature: {
      hash: Binary.createFromBase64('AAAAAAAAAAAAAAAAAAAAAAAAAA=', 0),
      keyId: Long('0')
    }
  },
  operationTime: Timestamp({ t: 1745611315, i: 14 })
}
sh.addShard("shardSet2/localhost:27022")
{
  shardAdded: 'shardSet2',
  ok: 1,
  '$clusterTime': {
    clusterTime: Timestamp({ t: 1745611324, i: 24 }),
    signature: {
      hash: Binary.createFromBase64('AAAAAAAAAAAAAAAAAAAAAAAAAA=', 0),
      keyId: Long('0')
    }
  },
  operationTime: Timestamp({ t: 1745611324, i: 18 })
}

```

Рисунок 7.17 – Додавання «шардів»

Далі було налаштовано «шардинг» для колекції performance_test.sales.

```

sh.enableSharding("performance_test")
{
  ok: 1,
  '$clusterTime': {
    clusterTime: Timestamp({ t: 1745611409, i: 8 }),
    signature: {
      hash: Binary.createFromBase64('AAAAAAAAAAAAAAAAAAAAAAAAAA=', 0),
      keyId: Long('0')
    }
  },
  operationTime: Timestamp({ t: 1745611409, i: 5 })
}
sh.shardCollection("performance_test.sales", {"category": 1})
{
  collectionsSharded: 'performance_test.sales',
  ok: 1,
  '$clusterTime': {
    clusterTime: Timestamp({ t: 1745611426, i: 2 }),
    signature: {
      hash: Binary.createFromBase64('AAAAAAAAAAAAAAAAAAAAAAAAAA=', 0),
      keyId: Long('0')
    }
  },
  operationTime: Timestamp({ t: 1745611426, i: 1 })
}

```

Рисунок 7.18 – Налаштування «шардингу» для колекції

Для перевірки «шардингу» було виконано команду `sh.status()`.

```
sh.status()

shardingVersion

{
  _id: 1,
  clusterId: ObjectId('680be9577880c11aa8f1ca37')
}

shards

[
  {
    _id: 'shardSet1',
    host: 'shardSet1/localhost:27021',
    state: 1,
    topologyTime: Timestamp({ t: 1745611315, i: 4 }),
    replSetConfigVersion: -1
  },
  {
    _id: 'shardSet2',
    host: 'shardSet2/localhost:27022',
    state: 1,
    topologyTime: Timestamp({ t: 1745611324, i: 9 }),
    replSetConfigVersion: -1
  }
]
```

Рисунок 7.19 – Частина виводу `sh.status()`

Додаткове завдання: візуалізація даних

Для візуалізації даних було створено новий скрипт `sales_per_category_chart.py`, де було використано бібліотеки `pymongo` та `matplotlib` для підключення до бд та візуалізації даних відповідно.

```
import matplotlib.pyplot as plt
from pymongo import MongoClient

client = MongoClient("mongodb://localhost:27017/")
db = client["performance_test"]
collection = db["sales"]

pipeline = [
  { "$group": { "_id": "$category", "count": { "$sum": 1 } } }
]

results = list(collection.aggregate(pipeline))

categories = [doc["_id"] for doc in results]
sales = [doc["count"] for doc in results]

plt.bar(categories, sales)
plt.xlabel("Category")
plt.ylabel("Total Sales")
plt.title("Sales per Category")
plt.show()
```

Рисунок 7.20 – Код скрипта




Рисунок 7.21 – Результат запуску програми

Висновок: під час роботи було розглянуто індексацію у MongoDB, реплікації та шардингу. Індексція – це один із способів оптимізації MongoDB для прискорення запитів. А реплікація, як засіб масштабування, покращує доступність даних та розподіл навантаження. У свою чергу, шардінг допомагає ефективно управляти великими обсягами даних, розподіляючи їх між вузлами.